


NLP & Generative AI: da zero all'applicazione RAG

- Per sviluppatori con basi in **Python**.
- Utilizzo esclusivo di modelli **open source** (nessuna API key).
- Esecuzione completa su **Google Colab** con **GPU T4** gratuita.



COSTRUIAMO APPLICAZIONI AI, NON MODELLI DA ZERO

APPROCCIO:


Imparare a usare gli
LLM come componenti
software.

RITMO:


6 lezioni da ~20 minuti,
teoria essenziale e
pratica immediata.

OBIETTIVO FINALE:

Un'applicazione reale,
costruita un blocco
alla volta.




LA MAPPA DEL CORSO: SEI TAPPE VERSO IL RAG



Il filo conduttore: evoluzione dell'analisi dati


Un unico dataset di recensioni e-commerce in italiano, arricchito ad ogni lezione.



L'ambiente di sviluppo: codice sorgente a portata di click



`github.com/ccasadei-maggioli/
corso-nlp-genai-2026`



Attivazione dell'accelerazione hardware (GPU T4)


Fondamentale per l'esecuzione dei modelli in tempo reale.

The diagram illustrates the process of activating hardware acceleration (GPU T4) in Google Colab. It shows the Google Colab interface with the 'Runtime' menu open, highlighting the 'Change runtime type' option (marked with a blue circle '1'). A line connects this option to a 'Notebook settings' dialog box (marked with a blue circle '2'). In the dialog, the 'Hardware accelerator' dropdown is set to 'T4 GPU'. Below this, there is an unchecked checkbox for 'Omit code' and 'Save' and 'Cancel' buttons. A line also connects the 'Notebook settings' dialog to a code cell containing the following Python code:

```
>>> import torch
>>> torch.cuda.is_available()
True // [System check passed]
```



Natural Language Processing: far comprendere il testo alle macchine

Oggi il dominio è dei modelli pre-addestrati su enormi quantità di testo. Noi li implementiamo e li adattiamo come moduli software.




L'unità di misura e il motore: Token e Transformer

Strumenti di esplorazione rapida: [Tokenizer playground](#) (Xenova) & [The Illustrated Transformer](#).




Large Language Models: generazione tramite predizione

- LLM: Un Transformer scalato che genera testo prevedendo il token successivo.
- Modelli Open di riferimento: Llama, Mistral, Qwen (Useremo Qwen2.5).
- Generative AI: Sfruttare la predizione per creare risposte, codice o riassunti.




Hugging Face: l'infrastruttura open source

- Migliaia di modelli pronti all'uso (LLM, embeddings, classificatori).
- Esecuzione locale su Colab: zero API key, nessun dato inviato a server esterni.



LangChain: il framework di orchestrazione

Dalla Lezione 5, il motore per trasformare un modello isolato in un'applicazione complessa (RAG).



Architettura di riferimento: Open Source vs API a pagamento

La motivazione ingegneristica dietro le scelte di questo corso.

	Modelli Open (Hugging Face)	API a pagamento (es. Cloud Services)
Costo	Gratis (hardware locale) ✓	A consumo
Privacy	Dati isolati e sicuri ✓	Dati inviati a terzi
Gestione Chiavi	Nessuna ✓	API key da gestire
Controllo	Totale (modifica pesi) ✓	Limitato (black box)

Execution: la prima pipeline di Sentiment Analysis

Nel notebook, analizziamo un dataset riproducibile di recensioni in una sola riga di codice.

Code to Output


```
classifier = pipeline("text-classification",  
    model="neuraly/bert-base-italian-cased-sentiment")  
  
classifier("Il display è fantastico!")
```



```
[{'label': 'POSITIVE', 'score': 0.98}]
```

Esercizio: Confronta l'output del modello con le stelle lasciate dall'utente nel dataset.

Checkpoint 1 completato: pronti per la ricerca semantica



[Materiale: github.com/ccasadei-maggioli/corso-nlp-genai-2026]