

NLP & Generative AI con Modelli Open Source


Lezione 4 di 6 — LLM generativi open source su GPU T4

In questa sessione:


Il Motore: Facciamo parlare un vero LLM: Qwen2.5-7B-Instruct

L'Ambiente: Tutto su Google Colab (GPU T4), abilitato dalla quantizzazione 4-bit


Il Caso d'Uso: Estrazione e analisi di recensioni clienti



Da dove veniamo, dove andiamo



Addestrati per eseguire una cosa sola




N Compiti, a parole: scrivono testo e seguono istruzioni complesse senza riaddestramento

Il Nostro Filo Conduttore

Continuiamo a lavorare sulle recensioni clienti in italiano. Nuovi Obiettivi: Generare riassunti, estrarre pro/contro e rispondere a domande libere sul testo.

Che cos'è un LLM generativo?

Una macchina statistica che predice il token successivo.




La Magia dell'Emergenza

Da questo semplice meccanismo emergono capacità avanzate di riassunto, traduzione e ragionamento logico — senza alcun addestramento dedicato a queste specifiche task. Glielo chiediamo a parole: questo è il cuore della Generative AI.


I Parametri di Sampling

Come il modello sceglie il token successivo



temperature = 0.0

Deterministico: sceglie sempre il token più probabile.



temperature = 0.7 – 0.9

Creativo: dà chance a token meno scontati.

Parameter 1	top_p (nucleus) — Considera solo i token più probabili fino a raggiungere una probabilità cumulata p (es. 0.9).
Parameter 2	max_new_tokens — Limite massimo di token generati. Governa lunghezza e tempi di calcolo.

Regola Pratica per Sviluppatori:

- Estrazione dati strutturati o Classificazione -> temperature = 0
- Scrittura creativa o discorsiva per esseri umani -> temperature = 0.7

Il Problema Hardware

Un modello da 7B non entra in una T4

La Matematica della Memoria:


Un modello da 7 miliardi di parametri in formato fp16 (2 byte per parametro) richiede ~14 GB solo per caricare i pesi in memoria.

La GPU T4 standard offerta da Google Colab ha ~15 GB di VRAM totale.

Il Risultato:

Il modello entra a malapena. Non rimane spazio sufficiente per le operazioni matematiche, il contesto testuale (KV Cache) o la generazione dei nuovi token.


L'esecuzione si schianta inevitabilmente.




La Soluzione: Quantizzazione 4-bit

Comprimiamo i pesi del modello per farli stare nella VRAM

Formato	Byte / Parametro	Peso Totale (7B)	Compatibilità GPU T4
fp16 (Standard)	2 byte	~14 GB	Error: Out of Memory
4-bit (nf4)	0.5 byte	~5-6 GB	Perfetto, con largo margine



15 GB VRAM




15 GB VRAM

Riduciamo la precisione numerica dei pesi da 16-bit a 4-bit. Si perde una frazione microscopica di precisione, ma la qualità dell'output testuale rimane ottima. È la tecnologia abilitante per l'hardware accessibile.

Il Chat Template (I Ruoli)

I modelli Instruct richiedono dialoghi strutturati, non testo grezzo.



La funzione `apply_chat_template` converte in automatico questo array Python nel formato di testo esatto (inclusi i tag speciali invisibili) che il modello si aspetta di ricevere.

Demo: Caricare Qwen2.5-7B in 4-bit

Il codice necessario su Colab

```
# 1. Installazione dipendenze
```

```
pip install transformers accelerate bitsandbytes
```

```
# 2. Configurazione della Quantizzazione
```

```
bnb = BitsAndBytesConfig(  
    load_in_4bit=True,  
    bnb_4bit_quant_type='nf4'  
)
```

```
# 3. Caricamento in VRAM
```

```
AutoModelForCausalLM.from_pretrained(  
    model_id, quantization_config=bnb, device_map='auto'  
)
```


Modello caricato.

Memoria GPU usata: 5.4 GB

Nota Operazionale: La prima esecuzione richiede 1–3 minuti per il download dei pesi. Le esecuzioni successive useranno solo ~5–6 GB di GPU.

Demo: La funzione genera(...)

Creiamo un wrapper riutilizzabile per l'inferenza



Per mantenere pulito il codice, abbiamo incapsulato l'intero ciclo di vita della richiesta in un'unica funzione. Nel notebook troverai la cella pronta per testare la tua prima generazione in italiano.

Demo: Analisi delle Recensioni

Mettiamo il modello al lavoro sui dati reali

Testo di Input

Questo prodotto ha superato le mie aspettative. La qualità costruttiva è eccellente e l'interfaccia utente è molto intuitiva. Tuttavia, il prezzo è un po' elevato e la durata della batteria potrebbe essere migliore. Nel complesso, un ottimo acquisto.

Riassunto in 3 punti

temperature = 0.5

- La qualità costruttiva è eccellente e l'interfaccia intuitiva.
- Il prezzo è considerato elevato.
- La durata della batteria è un punto debole.

Cerca il giusto equilibrio tra aderenza ai fatti e fluidità del testo.

Pro / Contro in elenco

temperature = 0.2

PRO

- + Qualità costruttiva eccellente
- + Interfaccia utente intuitiva

CONTRO

- Prezzo elevato
- Durata della batteria migliorabile

Bassa creatività, massima fedeltà ai dati presenti nel testo per un'estrazione precisa.

Q&A mirato

temperature = 0.0

L'utente apprezza la qualità costruttiva e l'interfaccia, ma critica il prezzo e la batteria.

Estrazione pura: risposta basata esclusivamente sul testo, rischio di allucinazioni pari a zero.

Prompting: Vago vs Ben Fatto

La qualità dell'output dipende esattamente dall'input (Stesso modello, stessa recensione)

Il Prompt Vago

Richiesta:

'Cosa ne pensi di questa recensione?'

Questa recensione sembra abbastanza positiva nel complesso, menziona diversi punti chiave che sono importanti per i potenziali acquirenti. L'utente sottolinea che la qualità costruttiva è eccellente e l'interfaccia è intuitiva, il che è ottimo. Tuttavia, c'è una nota negativa riguardo prezzo che è considerato un po' alto, e anche la durata della batteria potrebbe essere migliorata. Alla fine, concludono che è un ottimo acquisto, quindi sembra che i pro superino i contro. È una buona sintesi.

Una risposta discorsiva generica, dispersiva, e impossibile da automatizzare e parsare in un software downstream.

Il Prompt Ben Fatto

Richiesta:


system prompt rigido + istruzioni chiare su cosa cercare e in che formato esatto restituirlo.

- ****Tema:**** Valutazione del prodotto
- ****Tono:**** Positivo, equilibrato
- ****Pro:****
 - Qualità costruttiva eccellente
 - Interfaccia utente intuitiva
- ****Contro:****
 - Prezzo elevato
 - Durata della batteria migliorabile
- ****Giudizio Complessivo:**** Ottimo acquisto

Una risposta altamente strutturata, deterministica e immediatamente utile per l'integrazione di sistema.

L'Effetto della Temperature

Stesso prompt, esecuzioni multiple sulla stessa macchina, comportamenti opposti



La risposta è diversa ad ogni esecuzione. Introduce **varianza statistica** ed esplora token secondari. Ideale per **generare varianti di copy**.

Alternativa più leggera: Qwen2.5-3B

Un piano B di emergenza se la T4 risulta troppo lenta o va in Out Of Memory

Qwen-7B	
Quality:	High
Speed:	Normal
VRAM:	~5.5 GB

Qwen-3B 	
Quality:	Good
Speed:	FAST
VRAM:	Low

Basta cambiare una stringa: Sostituisci semplicemente `model_id = 'Qwen/Qwen2.5-3B-Instruct'` nel notebook e riesegui la cella di caricamento.

Vantaggi: Il modello è grande meno della metà, garantisce risposte molto più rapide e un'impronta in VRAM quasi inesistente. La qualità di ragionamento logico è lievemente inferiore rispetto al 7B, ma del tutto adeguata per questa lezione.

Esercizio Pratico

Tocca a te costruire il prompt perfetto

Esercizio.py

```
1 system_prompt = '' # TODO: inserisci le istruzioni
2 user_prompt = '' # TODO: inserisci i dati e la richiesta
```


I tuoi task nel Notebook:


1. **L'Obiettivo:** Date le recensioni di un prodotto, produci una risposta dell'assistenza clienti.
2. **I Requisiti:** Massimo 3-4 frasi. Ringrazia il cliente per il feedback e rassicuralo sui punti critici specifici sollevati nel testo.
3. **Completa** le variabili vuote (TODO) per definire accuratamente i messaggi di system e user.
4. **Variante avanzata:** Modifica l'architettura del prompt per estrarre solo i pro e contro di un prodotto diverso, forzando la risposta in un rigoroso formato a elenco.

(La soluzione completa commentata è fornita in fondo al notebook).


Riepilogo & Prossimi Passi

Oggi: Le Fondamenta

 Meccanica	 Ingegneria	 Pratica
Dominato la generazione probabilistica e il sampling (temperature, top_p).	Aggirato l'OOM con la quantizzazione 4-bit, passando da ~14GB a ~5GB di VRAM.	Scritto genera(), sfruttato i Chat Templates e applicato il Prompting strutturato.



Lezione 5: LangChain e Automazione



Finora abbiamo scritto prompt 'a mano' concatenando stringhe Python. Nella prossima lezione introdurremo **LangChain**:

- Prompt Template modulari e riutilizzabili.
- Catene di esecuzione (LCEL) e Parser per costringere gli output in JSON nativo.
- Questo è il ponte tecnologico vitale verso il Progetto Finale con RAG (Lezione 6).