



Progetto Finale: Analisi Recensioni con RAG

Costruire un'app Q&A basata sui propri dati, con citazione delle fonti.




[Stack]	100% Open Source
[Hardware]	Google Colab + GPU T4
[Output]	Risposte verificabili

Il Viaggio e L'Obiettivo



Oggi non aggiungiamo un nuovo mattone. Li assembliamo tutti per creare un'architettura completa.

Il Problema: L'Isolamento dell'LLM




La Realtà

- **Un LLM conosce solo i dati del suo addestramento originale.**
- **Le nostre recensioni NON sono nel modello.**
- **Senza contesto specifico, l'LLM è costretto a indovinare (Allucinazioni).**

Servono risposte fondate sui nostri dati e, soprattutto, verificabili.

La Soluzione: Retrieval-Augmented Generation

Ricerca Semantica (L2) + LLM Generativo (L4) = RAG



Meno Allucinazioni: Risposte basate su fatti.




Knowledge Aggiornabile: Non serve riaddestrare il modello.



Fonti Citabili: Tracciabilità totale del dato.

L'Architettura RAG Completa




i

Una chiara separazione tra la preparazione del database e il ciclo di risposta in tempo reale.


Strategia di Chunking: Adattarsi al Dato

Documenti Lunghi (es. PDF)



Richiede un text splitter per mantenere il contesto nei limiti dell'LLM ed evitare rumore nella ricerca.


Le Nostre Recensioni



Le recensioni sono già brevi (poche frasi).


**Regola: 1 recensione = 1 documento.
Nessuno split necessario.**

Mappa del Riuso dei Componenti



> Il vero valore ingegneristico non risiede nei singoli componenti, ma nella loro orchestrazione.


Fase A - Arricchimento del Dato



```
pipeline("text-classification", model="neuraly/bert-base-italian-cased-sentiment")
```

Aggiungere i tag di sentiment prima dell'indicizzazione è vitale per il cruscotto analitico e per i filtri avanzati in fase di retrieval.

Fase B - Vector Store FAISS



Parametri Tecnici

- Modello Embeddings:

"intfloat/multilingual-e5-base"

- Struttura Documento:

"Document(page_content=testo, metadata={id, prodotto, rating})"


- Ogni recensione diventa un vettore matematico nel database FAISS.

- I metadati sono essenziali: Permettono di citare la fonte esatta (id) o di applicare filtri mirati (es. ricerca solo su un prodotto).

"as_retriever(search_kwargs={"k": 4})" → Il retriever estrarrà le 4 recensioni più rilevanti.

Fase C - Qwen 4-bit in LangChain

Hardware Monitor




Technical Constraints & Setup

- **Modello:** "Qwen2.5-7B-Instruct"
- **Quantizzazione:** "load_in_4bit=True"
(Permette al modello di girare nei 16GB della GPU T4, occupandone solo 5-6 GB).
- **Wrapper LangChain:** Utilizziamo "ChatHuggingFace" per gestire automaticamente il chat template specifico del modello.



Il primo download richiede 1-3 minuti. Le successive generazioni impiegheranno solo pochi secondi.

Fase D - La Catena RAG con LCEL



Le Regole d'Oro del System Prompt

1. Usa **ESCLUSIVAMENTE** il contesto fornito.
2. Cita sempre gli ID delle recensioni tra parentesi quadre (es. [ID: 104]).
3. Se l'informazione non è presente, ammetti di non saperlo.

```
catena = {"contesto": retriever | formatta_contesto, "domanda": passthrough} | prompt | chat | parser
```


Demo - Q&A con Fonti Verificabili

Interfaccia Utente

Cosa lamentano i clienti sulla spedizione?

I clienti segnalano frequenti ritardi nelle consegne, in particolare per le spedizioni verso le isole [ID: 45], [ID: 112]. Un utente lamenta imballaggi danneggiati [ID: 89].

Log Backend (FAISS)

[ID: 45]

Testo: Ritardo di 4 giorni in Sicilia...

[ID: 112]

Testo: Arrivato in Sardegna dopo una settimana.

[ID: 89]

Testo: Scatola esterna completamente schiacciata.

Trasparenza totale. Ogni affermazione è riconducibile al dato originale.

Fase E - Il Cruscotto Business

The Quantitative View

Prodotto	Num. Recensioni	Media Rating	% Sentiment Negativo
Prodotto A	1,245	4.3	15%
Prodotto B	980	3.9	22%
Prodotto C	2,100	4.7	5%


The Qualitative View

> RAG: Analizza le recensioni negative per 'Prodotto A'. Quali sono i problemi principali?

> [RAG Response]: I clienti segnalano problemi con la durata della batteria dopo l'ultimo aggiornamento firmware [ID: 502, 515] e difficoltà nel configurare la connessione Wi-fi iniziale [ID: 530]. La maggior parte delle recensioni negative recenti si concentra su questi due aspetti.

Il cruscotto quantitativo ti dice quale prodotto ha dei problemi. Il RAG qualitativo ti spiega il perché.

Esercizio Pratico: Il Tuo Turno



Nota: La soluzione completa è disponibile nel notebook del corso.

Conclusione e Prossimi Passi

Fatto [✓]	Limiti Attuali [⚠]	Verso la Produzione [🚀]
• App RAG end-to-end con fonti citabili. • Cruscotto analitico integrato. • Tutto open-source su hardware gratuito.	• Allucinazioni ridotte, ma mai del tutto azzerate. • Qualità limitata dal retriever (Garbage in, garbage out). • Capacità limitata del modello 7B.	• Integrazione di modelli di Re-ranking. • Valutazione metrica sistematica (es. Faithfulness). • Deploy con API REST e Vector Store persistente.